

דוח מטלה 1: איסוף נתוני סרטים

קורס: כריה וניתוח נתונים מתקדם

צוות: 14

מגישים: אלכסנדר ציריס (1111111), יואב ביג'אוי (2222222)

מספר הסרטים שנאספו

בסיום תהליך איסוף הנתונים, הסינונים והמיזוגים מ IMDb ו Wikipedia, סט הנתונים הסופי שלנו כולל 19,860 סרטים.

החלטות מרכזיות שנלקחו בבניית סט הנתונים.

במהלך העבודה על הפרויקט קיבלנו מספר החלטות כדי לדאוג שהדאטה יהיה נקי ואמין:

- **סינון ראשוני (IMDb):** שמרנו רק שורות מסוג movie, הגבלנו את שנת היציאה עד 2024, וסינונו לסרטים שאורכם בין 60 ל-300 דקות. בנוסף, הוספנו מסכה (mask_n_o) ששומרת סרטים שמתחילים (באותיות O ו N-גדולות וקטנות) בהתאם לחלוקה.
- **טיפול בערכים חסרים (Drop & Fill):** ראינו שיש סרטים בלי שנת יציאה או אורך מוגדר. מאחר ואלו נתונים בסיסיים, בחרנו למחוק את השורות האלו. (dropna) בעמודת ההצבעות (numVotes), מילאנו ערכים חסרים ב-0 תחת ההנחה שסרט ללא דירוג פשוט לא צבר מצביעים. לאחר מכן המרנו את העמודות הללו ל Integer.
- **שליפת 5 השחקנים המובילים:** מתוך טבלת principals, סינונו רק שחקנים (actor), ביצענו קיבוץ (groupby) לפי ה-ID של הסרט (tconst), והפעלנו פונקציה שחותכת את הרשימה לעד 5 שחקנים כדי למנוע רשימות ארוכות מדי.
- **איסוף הנתונים מויקיפדיה (Web Scraping)**
 - השתמשנו ב BeautifulSoup כדי לחפש סרטים. כדי שהקוד ירוץ על כמעט 20 אלף רשומות בלי להיחסם, הוספנו השהייה. (time.sleep(0.5))
 - **מנגנון שמירת ביניים:** בגלל זמן הריצה הארוך, הוספנו שמירה לקובץ גיבוי (wiki_backup_all.csv) כל 100 איטרציות כדי שלא נאבד נתונים במקרה של קריסת רשת. בסוף טענו את קובץ הגיבוי וביצענו LEFT JOIN עם הנתונים מ IMDb
- **ניקוי נתוני כסף:** הנתונים של התקציב וההכנסות הגיעו כטקסט עם הערות שוליים (כמו [5]בנינו פונקציה מבוססת Regex שמנקה את הטקסט. נתקלנו גם בבעיה שמספרים גדולים הופיעו לפעמים עם נקודות (למשל 0900.000.00) ולכן הוספנו תנאי שמזהה מפריד אלפים כזה, מתקן אותו וממיר את הסכומים לממוצע (במידה והיה טווח) במיליוני דולרים (Float).
- **סידור ז'אנרים:** בעזרת פונקציית split המרנו את עמודת הז'אנרים ממחרזות בודדת לרשימה של מחרוזות (List of Strings)

אחוז ומספר הערכים החסרים בכל עמודה

הטבלה הבאה מציגה את סיכום הערכים החסרים בסט הנתונים הסופי שיצרנו:

		סוג נתון	כמות ערכים חסרים	(%) אחוז ערכים חסרים
tconst	object		0	0.00
primaryTitle	object		0	0.00
startYear	int32		0	0.00
genres	object		0	0.00
lead_actors_ids	object		3593	18.09
runtimeMinutes	int32		0	0.00
averageRating	float64		6174	31.09
numVotes	int32		0	0.00
Language	object		17204	86.63
Country	object		17265	86.93
budget	float64		19442	97.90
BoxOffice	float64		19362	97.49
plot	object		16014	80.63

הערה על אחוז הערכים החסרים: אפשר לראות שנתוני ויקיפדיה (תקציב, הכנסות, מדינה) מכילים אחוז חסרים גבוה מאוד. הסיבה לכך היא שהדאטה שלנו כולל אלפי סרטים ישנים (מתחילת המאה ה-20) וסרטי אינדי, שלרובם אין דפי ויקיפדיה מסודרים באנגלית עם Infobox ובטח שלא מפורסמים עבורם נתוני תקציב. בנוסף, חלק מהחיפושים הובילו לדפי פירושונים (Disambiguation) במקום לערך הסרט עצמו. בחרנו להשאיר את הנתונים כפי שהם משום שזה משקף דאטה אמיתי.